

Atividade 03

- **Aluno:** Manuel Ferreira Junior
- **Disciplina:** Processamento Digital de Imagens

Questão 01

Para esta questão, considere as imagens:

Pattern1.png

Pattern1_blur.png

Pattern1_blur2.png

Pattern2.png


As imagens Pattern1_blur e Pattern1_blur2 são versões embaçadas com diferentes intensidades da imagem Pattern1.

A)

Nas imagens Pattern1 e Pattern2, calcule a magnitude da Transformada de Fourier e disserte sobre esse gráfico em relação às imagens originais, observando o que acontece com as altas e baixas frequências.

R.:

Como pode ser visto na questão, a transformada de Fourier é uma ferramenta essencial para análise da frequência dos contrastes na imagem, podendo ajudar a identificar padrões espaciais distribuídos ao longo da imagem original, a partir de análises de altas e baixas frequências. Nesse caso, para as imagens *Pattern1* e *Pattern2*, é possível observar dois comportamentos bem distintos como visto abaixo



A imagem *Pattern1* apresenta um padrão período, sendo ele definido por traçados diagonais bem definidos e contínuos, indicando uma periodicidade na estrutura da imagem, sendo evidenciado ainda mais ao analisar a FFT da imagem, com picos localizados e simétricos. O padrão regular encontrado na transformada de fourier evidencia o comportamento periodico da imagem original, devido a essa presença de picos e simetrias na magnitude da transformada.


A segunda imagem, *Pattern2*, possui um padrão mais desordenado, comparado a primeira imagem, não tendo um comportamento periodico completo e sim mais complexo. Contudo a imagem ainda que sem periodicidade completa, existe partes da imagem que apresentam alguma periodicidade mesmo que em pouco espaço. Aparentemente, existem uma interseção entre dois comportamentos, um horizontal e outro diagonal na imagem, isso se reflete na transformada de fourier, tendo uma distribuição mais espalhada, contudo com uma região circular no centro, com alguns picos ao longo do perímetro da circunferencia. Uma diferença clara entre as transformadas, que pode ser evidenciada mais claramente quando olhamos o plot 3D das transformadas, é a presença de 2 picos bem evidentes na primeira imagem *Pattern1*, enquanto a *Pattern2* apresenta alguns picos proximos dentro da circunferencia central.

Comparando ambas as imagens e suas transformadas, podemos notar que uma imagem com um comportamento periodico claro, ao longo da imagem completa (*Pattern1*) apresenta uma representação na magnitude da

transformada de fourier bem definida, com traços simétricos e com picos bem definidos; Já imagens com padrão tão complexos, como a sobreposição de comportamentos horizontais e diagonais, além da alteração da frequência dos tons, devem apresentar uma transformada com um comportamento mais complexos, como no exemplo, uma circunferência com raio bem definido, e diversos picos ao longo do centro.

B)

Agora, analise o que acontece com a magnitude da Transformada de Fourier à medida que filtros passa baixa vão sendo aplicados na imagem Pattern1 com intensidades cada vez mais fortes. Isso pode ser visto nas imagens Pattern_blur e Pattern_blur2; não é necessário embaçar mais a imagem original.



R.:

Logo após a primeira aplicação do filtro passa baixa, a imagem já tem seu ruído periódico retirado, os traços horizontais ao longo da imagem desaparecem e ocorre o efeito de borrramento esperado após aplicação do filtro. Analisando a transformada de Fourier, é mais nítida a cruz horizontal e vertical na magnitude bem definida, porém algumas altas frequências aparentam estar espalhadas ainda ao longo da matriz de transformada. Um ponto interessante de se ressaltar, é o desaparecimento dos picos de alta frequência anteriores, agora restando

apenas um pico de alta frequência, com alguns outros picos espalhados mas maioria centrado ao longo da cruz. Após aplicação do segundo filtro passa baixa, a cruz permanece ainda com altas frequência, mas ainda sim bem reduzidos comparado a primeira aplicação do filtro, e o comportamento das altas frequências espalhadas agora se encontram mais próxima do centro, ou seja, mais perto do pico de alta frequência da imagem.


Questão 04

Considere para esta questão as imagens:

Textura1.png

Textura2.png

Textura3.png



Textura 1

Textura 2

Textura 3

As imagens Textura1 e Textura2 são de um mesmo material (suponha Classe 1), tendo sido tiradas de partes diferentes desse material. Já a imagem Textura 3 é de um material diferente (suponha Classe 2). Implemente um algoritmo, automático e com apenas uso de técnicas vistas na disciplina, que consiga classificar essas imagens entre as Classes 1 e 2. Não pode usar técnicas de classificação de aprendizagem de máquina. Manipulações matemáticas ou estatísticas usuais podem ser usadas, sendo devidamente justificadas.

R.:

Solução 1) Coeficiente de variação

Vamos analisar, em conjunto, a variabilidade em torno da média da transformada de fourier, utilizando do **Coeficiente de Variação**, cuja formula pode ser expressa abaixo

$$CV_{\%} = \frac{\sigma}{\mu} \cdot 100$$

aonde

$$\begin{cases} \sigma : \text{Desvio padrão da magnitude da transformada de fourier} \\ \mu : \text{Média da magnitude da transformada de fourier} \end{cases}$$

Para tanto, considerando que o problema é binário, vamos fixar a imagem 1 (*Textura1*) como sendo uma referencia para a classe 1, e um threshold de permissão de 5% de variabilidade sobre essa imagem de referência, para que aquela textura pertença a classe 1. Vamos por partes, abaixo calculamos o desvio padrão para cada Textura.


```
stats_values = {}
for key, value in imgs.items():
    stats_values[key] = {
        "media": float(value["img_fft"].mean()),
        "desvio": float(value["img_fft"].std())
    }
    stats_values[key]["cv"] = 100 * (stats_values[key]["desvio"] /
stats_values[key]["media"])

data_stats = pd.DataFrame(stats_values).round(2)
data_stats
```

	Textura1	Textura2	Textura3
media	6.14	6.60	8.79
desvio	1.19	1.17	0.81
cv	19.43	17.75	9.26

Dado os coeficientes de variação acima, como definido antes, vamos utilizar o coeficiente de variação da imagem *Textura1* como referência, ou seja, 19.43%. Dessa forma, com 5% de permissão de variabilidade sobre o coeficiente de variação, temos o limite superior de 19.43% + 5% = 24.43% e limite inferior de 19.43% - 5% = 14.43%, ou seja, para que a textura seja da classe 1, então o coeficiente de variação da imagem deve estar entre temos definido a regra abaixo:

$$\begin{cases} i \in \text{Classe 1} : \text{se } 14.43 \leq cv_i \leq 24.43 \\ i \in \text{Classe 2} : \text{se } cv_i \leq 14.43 \text{ ou } cv_i \geq 24.43 \end{cases}$$

Por fim, temos um método automático para decisão se a textura exibida pertence ao mesmo padrão da 1 e da 2, ou seja, a classe 1.

Este método considera a variabilidade entre os valores de frequências na matriz de magnitudes de fourier, considerando o percentual de variabilidade em torno da média. Dessa forma, o algoritmo leva em consideração a média dos pixels e o desvio padrão da imagem.

Solução 02) Mean Absolute Percentage Error - MAPE

É possível também, utilizando a *Textura1* como padrão para comparação sobre a classe 1, também podemos aplicar calculos matemáticos para comparar uma nova textura com a imagem utilizada. Dessa forma, vamos utilizar a métrica conhecida como *Mean Absolute Percentage Error* (MAPE), para compararmos novas texturas com a escolhida para representar a classe 1. Essa métrica tem como intuito avaliar o quão próximo uma estimativa esta próxima ao valor real; nesse contexto, vamos considerar como uma proximidade, ou seja, quão próximo a 0, mais próximo as frequências de magnitude da transformada de fourier da imagem em questão estão da imagem a ser comparada, apresentando características próximas.

A formula para o MAPE, adaptada para a situação matricial, pode ser expressa abaixo:

$$MAPE_{\%} = 100 \cdot \sum_{j=1}^m \sum_{i=1}^n \frac{|y_{ij} - \hat{y}_{ij}|}{|y_{ij}|}$$

sendo:

$\begin{cases} y_{ij} : i\text{-ésima linha e } j\text{-ésima coluna da matriz de transformada de fourier para a matriz de referência} \\ \hat{y}_{ij} : i\text{-ésima linha e } j\text{-ésima coluna da matriz de transformada de fourier para a matriz de comparação} \end{cases}$

Será necessário considerar também um threshold para garantir um comportamento parecido entre ambas frequências na matriz de magnitude de fourier. Vamos considerar um threshold de 25% para que seja considerado uma imagem similar a de comparação, ou seja, se $MAPE_{\%} < 25\%$, então a imagem pertence a classe 1; caso contrário, pertence a classe 2.

$$\begin{cases} i \in \text{Classe 1} : \text{ se } MAPE_{\%} \leq 25\% \\ i \in \text{Classe 2} : \text{ se } MAPE_{\%} > 25\% \end{cases}$$

Abaixo, vamos calcular esses valores:

```
def mape(y_true, y_pred):
    """Calcula o erro percentual médio absoluto (MAPE)"""
    y_true, y_pred = np.array(y_true), np.array(y_pred)
    return np.mean(np.abs((y_true - y_pred) / y_true)) * 100

img_refer = "Textura1"
data_mapes = {}
for key in ["Textura2", "Textura3"]:
    data_mapes[key] = {
        "mape": mape(
            imgs[img_refer]["img_fft"].flatten(),
            imgs[key]["img_fft"].flatten()
        )
    }
data_mapes = pd.DataFrame(data_mapes).round(2)
data_mapes
```

	Textura2	Textura3
mape	14.65	47.97

Acima, podemos ver que para a *Textura2* o valor de MAPE foi inferior ao threshold escolhido, então podemos afirmar que essa textura pertence a classe 1 também, já a *Textura3*, o valor é superior, logo pela regra sera considerado da classe 2.

Com todas as regras definidas, temos bem claro um algoritmo automático para decisão a qual classe a textura pertence.

Solução 03) Estatística de Komolgorov-Smirnov

Nesta solução, podemos utilizar a estatística calculada para o teste de Komolgorov-Smirnov, aonde o intuito é calcular a distância entre duas distribuições e mensurar quão próximas elas são. A formula é definida abaixo:

$$D = \max_n |F_n(x) - F(x)|$$

Sendo "D" então como a máxima distância entre as distribuições acumuladas empirica amostrada ($F_n(x)$) e a distribuição acumulada empirica a ser comparada ($F(x)$). No contexto atual, vamos considerar como $F_n(x)$ sendo a distribuição acumulada empirica magnitude obtida apartir da transformada de fourier para as imagens *Textura2* e *Textura3* a compararem com a distribuica acumulada empirica da magnitude da transformada de fourier para a

imagem *Textura1* ($F(x)$). Para usar essa métrica, também é necessário selecionar um threshold, e dessa forma vamos fixar um valor de até 0.5 para ser considerada da classe 1, caso contrário, será da classe 2, logo:

$$\begin{cases} i \in \text{Classe 1} : \text{se } D \leq 0.5 \\ i \in \text{Classe 2} : \text{se } D > 0.5 \end{cases}$$

Abaixo podemos visualizar o proximo, aonde na primeira imagem é feito a comparação da distribuição entre os histogramas das imagens, evidenciando claramente um distribuição afastada para a imagem *Textura3* longe das outras duas. Olhando para a segunda imagem, é possível ver as distribuições de $F_n(x)$ para todas as texturas, mostrando a diferença de distribuições entre as classes.

```
def ecdf(data):
    """Calcula a distribuição acumulada empírica (ECDF)."""
    sorted_data = np.sort(data)
    cumulative = np.arange(1, len(sorted_data) + 1) / len(sorted_data)
    return sorted_data, cumulative


img_refer = "Textura1"
ecdfs = {}
distances = {}
# Plots
fig, ax = plt.subplots(1, 2, figsize=(20, 8))
for key, img in imgs.items():
    dist = img["img_fft"].flatten()
    x, y = ecdf(dist)
    ecdfs[key] = {"x": x, "y": y}
    # Plotar a Distribuição de Densidade de Kernel (KDE)
    sns.kdeplot(dist, label=f"{key} - KDE", fill=True, alpha=0.3, ax=ax[0])

    # Calculo da estatística KS
    if key != img_refer:
        distances[key] = {
            "ks": float(ks_2samp(imgs[img_refer]["img_fft"].flatten(),
dist).statistic)
        }

    # Plotar a Função de Densidade Acumulada (CDF)
    if key != img_refer:
        ax[1].plot(
            x,
            y,
            label=f"{key} - ECDF - Distance: {:.2f}".format(key, distances[key]
['ks']),
            linestyle="--"
        )
    else:
        ax[1].plot(
            x,
            y,
            label=f"{key} - ECDF",
            linestyle="--"
        )
```

```
# Configurar o gráfico
ax[0].set_title("Distribuição e Densidade Acumulada das Magnitudes da FFT")
ax[0].set_xlabel("Valores de Magnitude")
ax[0].set_ylabel("Densidade / Probabilidade Acumulada")
ax[1].set_title("Função de Densidade Acumulada (CDF)")
ax[1].set_xlabel("Valores de Magnitude")
ax[1].set_ylabel("Probabilidade Acumulada")
ax[1].set_ylim(0, 1)
for _ax in ax.flatten():
    _ax.spines[["top", "right"]].set_visible(False)
    _ax.legend()

fig.tight_layout()
fig.savefig(path_assets / "atv03_q04-02.png", dpi=400)
plt.show()
```



Como visto no gráfico, temos um valor de $D = 0.21$ para a *Textura2* e um valor de $D = 0.82$ para a *Textura3*, então pela regra de decisão definida, temos que a textura 2 pertence a classe 1 e a textura 3 pertence a classe 2.

Dessa forma, temos um meio automático para decisão a qual classe pertence a textura testada.